

Self-attention

Self-attention

INPUT

如何应对复杂长度的文字处理（输入不同长度，多个向量）

- one-hot encoding

apple = [1 0 0 0 0 0]


bag = [0 1 0 0 0 0]

cat = [0 0 1 0 0]

dog = [0 0 0 1 0]

elephant = [0 0 0 0 1]

- word embedding



音频25ms是一个向量
图网络的一个节点是一个向量
一个分子也可以看成一个向量

OUTPUT

- each vector has a label
N个向量输出N个结果
- the whole sequence has a label
N个向量输出一个结果
- model decides the number of labels itself
N个向量不知道输出多少个结果
seq2seq

N2N


Sequence Labeling

Is it possible to consider the context?

FC can consider the neighbor


How to consider the whole sequence?

a window covers the whole sequence?



滑动窗口：只考虑到邻近，没考虑到全局，该怎么考虑全局？用窗口覆盖整个向量吗


Self-attention




图里的Self-attention结合了输入的所有信息，再传递给全连接层，再传给Self-attention，再传给全连接层，再输出

self-attention内部是如何运行的？


一种是dot-product点积的做法



一种是用tanh函数等激活函数这种



在实际应用中，最常用的一定是dot-product



这里的可以称为查询矩阵（向量），在计算一次的时候，表示输入向量i与输入向量j的注意力得分，i是不变的，要计算的是所有的j和它的得分
 对于一个查询矩阵，得到的是被查询，或者说要处理到的，要计算成绩的向量的自身标识

计算需要两个矩阵、


可以称为钥匙矩阵，是为了评估其他输入向量与我们关注的i向量的关系，计算得到

再做点积，得到注意力得分

需要说明的是，其中j是从1到n的，要做自己和自己的注意力得分

Self-attention

$$\alpha'_{1,i} = \exp(\alpha_{1,i}) / \sum_j \exp(\alpha_{1,j})$$



17

之后，添加一个softmax层做归一化


得到最终的注意力得分

算出得分后，要做的是基于得分，提取信息

Self-attention

Extract information based on attention scores

$$b^1 = \sum_i \alpha'_{1,i} v^i$$



引出第三个矩阵

其作用是根据注意力得分，抽取其中重要的信息

然后将每一个v乘上注意力得分得到b

如果有一个向量的得分很高，那得到的b就会很接近高向量对应的v

说人话就是权重


将上述过程用矩阵形式表达

Self-attention

$$q^i = W^q a^i \quad \begin{matrix} q^1 & q^2 & q^3 & q^4 \\ Q \end{matrix} = \begin{matrix} W^q & \begin{matrix} a^1 & a^2 & a^3 & a^4 \\ I \end{matrix} \end{matrix}$$

$$k^i = W^k a^i \quad \begin{matrix} k^1 & k^2 & k^3 & k^4 \\ K \end{matrix} = \begin{matrix} W^k & \begin{matrix} a^1 & a^2 & a^3 & a^4 \\ I \end{matrix} \end{matrix}$$


$$v^i = W^v a^i \quad \begin{matrix} v^1 & v^2 & v^3 & v^4 \\ V \end{matrix} = \begin{matrix} W^v & \begin{matrix} a^1 & a^2 & a^3 & a^4 \\ I \end{matrix} \end{matrix}$$



Self-attention

$$\begin{matrix} Q \\ K \\ V \end{matrix} = \begin{matrix} W^q \\ W^k \\ W^v \end{matrix} \begin{matrix} I \\ I \\ I \end{matrix}$$

Parameters to be learned




I就是input, A是注意力评分, O是结果

多头注意力机制

相比于单头, 区别在哪


Multi-head Self-attention Different types of relevance



看图里, 如果想要将输入的a生成两个q, 在生成第一个q后, 需要新添加新的两个矩阵, 生成两个q, 剩下的k, v也是同理这是矩阵的形式

Multi-head Self-attention Different types of relevance

$$b^i = W^O \begin{bmatrix} b^{i,1} \\ b^{i,2} \end{bmatrix}$$



在注意力机制中，需要计算的未知数就是几个W矩阵，其他都是已知的